

Annexes :

SOMMAIRE DES ANNEXES :

A: SCIENCES HUMAINES, PHILOSOPHIE ET THÉORIES DE LA VOIX (4 annexes) :

Annexe 1 : Justin Sung : Attention, effort mental et immédiateté

Annexe 2 : Jaron Lanier : Critique des systèmes algorithmiques et de la standardisation

Annexe 3 : Roland Barthes : Le « grain de la voix » et la matérialité vocale

Annexe 4 : Mladen Dolar & Adriana Cavarero : Voix, adresse et unicité

B: ARTS, MUSIQUE ET DISPOSITIFS IA (3 annexes) :

Annexe 5 : Reeps One & Nokia Bell Labs : « We Speak Music: Second Self »

Annexe 6 : Spike Jonze, Her : Voix désincarnée et relation à une IA vocale

Annexe 7 : Holly Herndon & Mat Dryhurst : PROTO et Holly+ (chœurs hybrides et gouvernance vocale)

C. TERRAIN ET SCÈNES BEATBOX (2 annexes)

Annexe 8 : Grand Beatbox Battle : Formats (solo, tag team, squad, loopstation) et critères d'écoute

Annexe 9 : Entretien avec Kassoum :

D. ANNEXE SECONDAIRE : APPROFONDISSEMENT PHYSIOLOGIQUE

Annexe 10 : Physiologie avancée de la voix : souffle, larynx, source–filtre et limites de l'IA vocale.

Annexe 1 : Justin Sung : Comment l'IA détruit lentement votre cerveau

1. Présentation de la ressource

Justin Sung est médecin et pédagogue spécialisé dans les stratégies d'apprentissage.

Dans cette vidéo, il s'interroge sur les effets d'un usage intensif de l'IA (comme ChatGPT) sur le cerveau humain : mémoire, attention, capacité d'analyse et créativité. Son but n'est pas de condamner l'outil, mais de montrer comment une utilisation passive peut affaiblir le développement cognitif.

2. Résumé de la vidéo

Sung explique que l'IA fournit des réponses immédiates, claires et souvent très complètes. À force de s'y habituer, l'utilisateur tend à :

- moins mobiliser sa mémoire et son raisonnement : l'IA propose des solutions "toutes faites", le cerveau n'a plus besoin de chercher, comparer, reformuler ;
- adopter une pensée plus uniforme : les réponses sont calibrées pour être correctes et neutres, ce qui tire la réflexion vers une forme de standard moyen, moins nuancée ;
- réduire son effort mental : face à une difficulté, le réflexe devient de demander à l'IA plutôt que de soutenir l'effort nécessaire pour résoudre le problème soi-même ;
- s'habituer à l'immédiateté : la patience pour des tâches longues (lire en profondeur, écrire, apprendre un geste complexe) diminue, car le cerveau attend une récompense rapide.

Pour limiter ces effets, Sung propose de :

- réfléchir d'abord par soi-même,
- utiliser l'IA comme interlocuteur à questionner, pas comme réponse finale,
- maintenir des activités qui sollicitent la mémoire, la créativité et le raisonnement sans assistance.

3. Prolongements pour la voix et le beatbox

Ce regard sur l'IA appliquée à l'apprentissage éclaire directement ce qui se joue dans une pratique comme le beatbox.

Micro-gestes et mémoire corporelle

Chaque son de beatbox repose sur des micro-ajustements du corps : tension des lèvres, position de la langue, pression du souffle, coordination avec le rythme.

Si l'on s'appuie trop vite sur des sons ou des modèles générés par IA, on peut obtenir un rendu convaincant sans avoir vraiment exploré ces gestes. Le résultat est là, mais la mémoire kinesthésique (ce que le corps a appris) est moins construite.

Temporalité du souffle et sens du timing

Le beatbox n'est pas qu'une succession de sons, c'est une gestion du temps par le souffle. Les micro-pauses, les relances, les accélérations rendent la performance vivante.

Des outils IA ou des boucles trop parfaites peuvent lisser ces variations et habituer l'oreille à un flux trop régulier, au risque de faire perdre la sensibilité au timing interne du corps.

Effort visible et perception du public

Sung insiste sur le fait que l'IA produit un résultat sans effort. En live, au contraire, le public lit la respiration, la tension musculaire, les risques pris.

En beatbox, cette lecture de l'effort fait partie de l'émotion : on n'écoute pas seulement un son, on voit quelqu'un qui s'engage physiquement. Un rendu artificiel peut être plus propre, mais il ne donne pas cette "mesure" de l'effort nécessaire.

Variabilité vocale et singularité

La voix humaine change selon la fatigue, l'émotion, la posture, l'acoustique. Ces variations créent un "grain vivant" qui rend chaque performance unique.

Un modèle IA, lui, tend à stabiliser le timbre et le geste. En pratique, cela peut pousser à considérer les irrégularités naturelles comme des défauts, alors qu'elles participent à la singularité d'un beatboxer.

Apprentissage et improvisation

Enfin, chaque progrès en beatbox vient d'un long processus d'essais, d'échecs et d'ajustements. Une utilisation trop confortable de l'IA peut réduire ce temps d'exploration, donc limiter, à terme, la capacité d'improviser et de s'adapter en live.

4. Avis personnel

Ce que je retiens de cette ressource, c'est que le danger principal n'est pas l'IA elle-même, mais la manière dont elle peut remplacer trop tôt l'effort nécessaire à

l'apprentissage.

Dans le beatbox, cela signifie que si je m'appuie trop sur l'IA pour générer des idées, des sons ou des corrections, je risque de construire un style "propre" mais moins incarné, avec une écoute moins fine de mon propre corps.

Pour que l'IA reste utile, je la vois plutôt comme un outil de comparaison ou de test :

- je peux m'en servir pour analyser, organiser ou challenger mes idées,
- mais l'acquisition réelle des sons, du souffle et du timing doit rester un travail physique, répété, que l'IA ne peut pas faire à ma place.

Annexe 2 : Jaron Lanier : You Are Not a Gadget: A Manifesto

1. Présentation de la ressource

Jaron Lanier est informaticien, musicien et pionnier de la réalité virtuelle. Dans *You Are Not a Gadget*, il critique la manière dont la culture numérique et les architectures de plateformes transforment notre façon de créer, d'écouter et de nous percevoir nous-mêmes.

Son point de départ est simple : les technologies ne sont pas neutres. Elles imposent des formes, des formats et des habitudes qui finissent par façonner aussi bien les artistes que le public.

2. Résumé de l'ouvrage

Lanier s'attaque à une idée centrale du numérique contemporain : la croyance que les systèmes algorithmiques et l'"intelligence collective" seraient supérieurs aux

choix individuels. Selon lui, cette vision pousse à réduire l'humain à des données manipulables.

Il montre que de nombreux outils – logiciels de création automatisée, Auto-Tune, algorithmes de recommandation, plateformes de publication, voire certains usages de l'open source – produisent une esthétique standardisée :

les styles se fondent, les voix singulières deviennent du “bruit” autour d'un même type de rendu jugé correct ou crédible.

Pour Lanier, le danger est double :

- du côté des artistes, une forme de dépossession créative : lorsqu'un outil propose spontanément ce qui “marche”, il devient de plus en plus difficile de développer un style qui s'en écarte vraiment ;
- du côté du public, un formatage de l'écoute : plus on consomme des contenus calibrés par les mêmes systèmes, plus il devient difficile d'apprécier une œuvre qui sort de la norme, qui est rugueuse, fragile ou trop singulière.

Il insiste sur le fait que l'information digitale ne représente jamais toute la réalité : en réduisant les expériences, les corps et les émotions à des flux de données, on perd justement ce qui fait la richesse d'une présence humaine.

3. Prolongements pour la voix et le beatbox

Les idées de Lanier entrent directement en résonance avec les arts vocaux et le beatbox.

Dans un environnement où les voix peuvent être clonées, corrigées, optimisées, l'outil technique a tendance à imposer sa propre idée de ce qu'est un “bon” son : propre, stable, aligné sur ce que les algorithmes ont identifié comme efficace.

Un beatboxer qui grandit dans ce contexte risque de mesurer sa valeur à ce standard : son timbre, son souffle, ses irrégularités peuvent lui sembler “mal faits” parce qu'ils ne correspondent pas à l'idéal contrôlé produit par la machine.

Lanier aide à formuler le problème :

- si les outils proposent en permanence des patterns vocaux fluides, des textures polies et des corrections instantanées, que reste-t-il à inventer pour l'artiste ?
- à force d'être guidé par des systèmes qui suggèrent ce qui fonctionne déjà, l'interprète ne risque-t-il pas d'intérioriser ces choix au point de ne plus oser décaler sa pratique ?

Transposé au beatbox, cela peut se traduire par :

- des routines pensées pour “sonner” comme ce que les plateformes privilégient ;
- une pression implicite pour lisser le souffle, gommer les accidents, rapprocher son style d’une esthétique déjà validée par les vues et les algorithmes ;
- une difficulté croissante à faire accepter sur scène ou en ligne une performance plus brute, plus risquée, où la voix se montre dans sa fragilité.

À l’inverse, le beatbox corporel peut être lu comme une forme de résistance à cette logique :

il remet au centre un corps qui respire, fatigue, transpire, et qui ne se plie pas facilement à un format unique. L’artiste montre que l’émotion peut venir d’un excès, d’un défaut assumé, d’un souffle trop court, d’un son imparfait mais intensément habité.

4. Avis personnel

Ce texte de Lanier m’aide à voir que le problème de l’IA et des plateformes ne se limite pas à la question “est-ce que la machine est créative ?”.

Le risque le plus profond est peut-être ailleurs : que les outils finissent par fixer silencieusement ce qui est considéré comme une bonne voix, une bonne performance, un bon mix, et que le public comme les artistes se calent dessus sans s’en rendre compte.

En tant que beatboxer, cela me pousse à me méfier des automatismes techniques “trop bien faits” : presets, effets, corrections qui m’emmènent spontanément vers un rendu déjà entendu.

L’enjeu, ce n’est pas de refuser la technologie, mais de garder une zone où ma voix peut rester un peu décalée, un peu excessive, où le souffle, les ratés et les choix bizarres ont encore le droit d’exister.

Cette annexe me sert donc surtout de rappel : si je laisse l’outil décider à ma place de ce qui est acceptable, je perds peu à peu la possibilité d’inventer une présence vocale vraiment singulière.

Annexe 3 : Roland Barthes : Le « grain de la voix »

1. Présentation

Dans son texte devenu classique sur la voix chantée, Roland Barthes oppose deux façons d'écouter :

- une écoute du sens (les paroles, la mélodie, la justesse, la structure),
- et une écoute du grain : la matérialité de la voix, le souffle, le timbre, la texture, tout ce qui vient du corps et déborde le simple message.

Pour éclairer cette notion, il compare deux interprètes de Lied :

Dietrich Fischer-Dieskau, symbole d'un contrôle technique impeccable, et Charles Panzéra, dont la voix laisse passer quelque chose de plus brut, de plus incarné.

Le « grain » désigne ce moment où l'on n'entend plus seulement une ligne musicale, mais un corps qui passe dans la voix. Ce n'est ni une technique, ni une intention consciente : c'est une empreinte irréductible, qui résiste à la reproduction et à la standardisation.

2. Résumé du texte

Barthes critique une écoute trop centrée sur la perfection formelle : belle émission, justesse, pureté du son.

Il propose de déplacer l'attention vers ce qui accroche l'oreille :

une respiration, une rugosité, une fatigue, une vibration un peu sale, un souffle trop court.

Ce « grain » est le lieu de la subjectivité incarnée :

- il ne se résume pas à la partition,
- il ne se laisse pas complètement noter, ni transcrire,
- il est lié à l'histoire, au corps, à la manière d'habiter une phrase.

La voix devient alors plus qu'un simple médium : elle est une signature corporelle, quelque chose qu'on reconnaît même si l'on ne comprend pas les mots. C'est aussi ce qui rend chaque voix fondamentalement non interchangeable.

3. Prolongements pour l'IA vocale et le beatbox

Les concepts de Barthes entrent directement en tension avec le développement des IA vocales actuelles.

a) Grain humain vs illusion de grain IA

Les synthèses vocales modernes ajoutent des souffles simulés, des micro-hésitations, des irrégularités calculées pour paraître “naturelles”. On a l'impression d'entendre une voix incarnée, alors qu'il s'agit d'une construction statistique.

Dans le beatbox, produire un kick ou un snare ne consiste pas seulement à déclencher un son :

c'est engager le souffle, la gorge, les lèvres, la salive, les muscles du visage.

L'IA peut imiter le résultat sonore, mais elle ne porte ni l'effort, ni la fatigue, ni le vécu qui se déposent dans un geste répété pendant des années.

b) Le grain comme compétence d'écoute

Barthes suggère que le grain n'est pas évident pour tout le monde. Il faut parfois une écoute plus fine, ou une expérience musicale, pour le repérer.

Transposé au beatbox :

- pour un spectateur non initié, une voix IA peut paraître “aussi bonne” qu'une voix humaine ;
- pour un beatboxer ou un auditeur averti, les indices organiques restent lisibles : respiration un peu désynchronisée, léger manque de souffle, attaques moins lisses.

Le problème, c'est que l'oreille peut se transformer. À force d'écouter des voix artificielles trop propres, on risque de perdre l'habitude de chercher ce grain vivant dans les voix réelles.

c) Vers des grains numériques ?

Certaines artistes, comme Holly Herndon, explorent déjà des chœurs hybrides où

des voix humaines et des voix synthétiques s'entremêlent. On n'est plus dans la simple imitation du corps : quelque chose comme un grain "autre" apparaît, qui ne renvoie plus directement à un larynx ou à un souffle identifiable.

Cette piste soulève une question :

si l'on accepte des "grains numériques" comme nouvelles références, que devient la voix humaine dans l'échelle de valeur ?

Le risque est que le critère de beauté se déplace vers des qualités impossibles pour un corps (régularité parfaite, endurance infinie), reléguant les voix incarnées au rang de versions imparfaites.

d) Beatbox et résistance au lissage

Dans ce contexte, le beatbox peut être lu comme une forme de résistance.

Il met en avant :

- l'effort visible,
- le souffle parfois à la limite,
- les sons qui "saturent",
- les accidents qui deviennent style.

Plutôt que de cacher ces aspérités, la performance les expose au micro. C'est exactement ce que Barthes valorise avec le "grain" : on n'applaudit pas seulement une propreté sonore, mais la présence d'un corps qui se met en jeu.

4. Avis personnel

Ce texte de Barthes me donne un vocabulaire pour quelque chose que je ressentais déjà sans savoir le nommer :

dans une performance vocale, ce qui me touche le plus n'est pas seulement la qualité du son, mais tout ce qui trahit l'effort, la fragilité, la manière de respirer.

Face à l'IA, le « grain de la voix » devient pour moi une sorte de repère : tant qu'on peut encore entendre un corps derrière la voix, avec ses limites et ses accidents, il reste une différence nette entre une performance humaine et une simulation.

Pour le beatbox en particulier, cette annexe me confirme une intuition :

si je gomme trop le souffle, les ratés, les petites rugosités de ma voix pour ressembler à un rendu parfait, je perds justement ce qui pourrait me distinguer d'une IA ou d'un preset.

Annexe 4 : Mladen Dolar & Adriana Cavarero : La voix comme objet philosophique

1. Présentation de la ressource

Mladen Dolar et Adriana Cavarero sont deux philosophes qui prennent la voix comme objet principal de réflexion.

Dans *Une voix et rien d'autre*, Dolar décrit la voix comme quelque chose qui déborde à la fois le langage et le simple son.

Dans *Pour une théorie de la voix*, Cavarero insiste sur le fait que chaque voix est liée à un corps singulier et à une adresse à quelqu'un : une voix dit d'abord « me voici », avant même de transmettre un message.

Ces deux approches prolongent et approfondissent ce que Barthes appelait le « grain » : elles déplacent la question vers ce que la voix révèle de l'existence d'un sujet et d'un corps.

2. Résumé des thèses principales

Pour Dolar, la voix est un objet paradoxal.

Elle n'est pas seulement un véhicule pour les mots, ni un bruit parmi d'autres. Elle est ce qui reste quand on a séparé le sens et la matière sonore : un reste qui signale une présence. La voix ne fait pas que dire quelque chose, elle est déjà une manière d'être là.

Cavarero, de son côté, insiste sur l'unicité de chaque voix.

L'écriture peut être anonyme, reproduite à l'infini, mais la voix est toujours incarnée : elle vient d'un corps précis, dans une situation précise, adressée à quelqu'un. On n'entend jamais une voix "en général", on entend toujours la voix de quelqu'un.

Ensemble, ces deux positions soutiennent l'idée suivante :

- la voix humaine n'est pas un simple signal que l'on pourrait copier à l'identique,
- elle porte la trace d'un sujet et d'un corps, et c'est cette trace qui la rend irréductible à une machine.

3. Prolongements pour l'IA vocale et le beatbox

Ces thèses prennent une importance particulière dès qu'on les confronte aux voix artificielles et à la pratique du beatbox.

a) Voix humaine vs voix générée

Les synthèses vocales modernes peuvent imiter le timbre, le rythme, les inflexions. Elles peuvent même simuler des "défauts" humains : souffle, hésitations, petites cassures.

Mais dans la perspective de Dolar et Cavarero, il manque quelque chose de décisif :

- la voix générée n'est pas le reste d'un corps qui parle,
- elle n'est pas la marque d'un sujet singulier adressé à quelqu'un,
- elle ne "risque" rien au moment où elle se fait entendre.

L'IA peut produire une voix techniquement parfaite, mais une voix parfaite n'est pas une voix humaine : elle n'a ni fatigue, ni vieillissement, ni contexte d'énonciation vécu.

b) Vers des voix "impossibles"

Des recherches récentes en audio et des projets artistiques imaginent déjà des voix qui n'existent pas biologiquement :

voix hybrides, voix multipliées, voix qui glissent d'un genre à l'autre ou d'une identité à l'autre sans aucune contrainte corporelle.

On n'est plus seulement dans la copie de la voix humaine, mais dans l'invention de nouveaux types de présence sonore.

Cela pose une question forte : si l'oreille s'habitue à ces voix "impossibles", que devient la valeur d'une voix ancrée dans un corps limité, qui respire, qui se trompe, qui vieillit ?

c) Risque de transformation de l'écoute

Le danger pointé par ces auteurs n'est pas que la voix humaine disparaisse : les gens continueront à parler, à chanter, à pratiquer le beatbox.

Le vrai risque est que notre manière d'écouter change :

- qu'on s'habitue à des voix optimisées, continuellement stables,

- qu'on perde la sensibilité aux fissures, au souffle, aux ratés qui témoignent d'une présence vivante.

Dans ce contexte, le beatbox apparaît comme un contrepoint :

il met en avant un corps en action, saturé de souffle, de salive, d'effort, avec des sons parfois à la limite du contrôle. Sa beauté vient précisément de cette fragilité, de cet excès qui échappent à la norme d'une voix lisse.

d) Beatbox et perte possible de valeur

Si les standards d'écoute sont dictés par des voix synthétiques toujours propres et tenues, le danger n'est pas que le beatbox cesse d'exister, mais qu'il soit perçu comme archaïque, brouillon ou "moins bon" que ses équivalents artificiels.

On peut imaginer un futur où une IA reproduit parfaitement des routines de beatbox, voire en invente, et où la dimension humaine (effort, risque, souffle) n'est plus ressentie comme un atout, mais comme une faiblesse.

4. Avis personnel

Ce que m'apportent Dolar et Cavarero, c'est une façon claire de dire que la voix n'est pas seulement un son, mais la trace d'un quelqu'un.

Dans le cadre de mon mémoire, cela renforce l'idée que le problème de l'IA n'est pas seulement technique (qualité de rendu), mais profondément lié à l'attribution : à qui est-ce que j'attribue ce que j'entends ?

Pour le beatbox, ces textes me rappellent que la force de cet art n'est pas uniquement dans la performance sonore, mais dans le fait qu'on voit et qu'on entend un corps lutter avec sa propre voix.

Si l'écoute se cale trop sur des voix artificielles parfaites, il faudra redoubler d'efforts pour rendre cette présence lisible et la défendre comme valeur artistique, pas comme défaut par rapport à la machine.

Annexe B1 : Reeps One : Beatbox vs IA (We Speak Music: Second Self)

1. Présentation de la ressource

Reeps One (Harry Yeff) est un beatboxer britannique reconnu comme l'un des artistes majeurs de la discipline. Son travail ne se limite pas à la performance : il explore aussi les liens entre voix, science et technologie.

Dans le projet We Speak Music: Second Self avec Nokia Bell Labs, il met en scène une expérience singulière : confronter en live son propre corps à une version IA de sa voix.

La performance n'est pas un simple concert augmenté d'effets : c'est une démonstration publique où l'artiste affronte un double numérique entraîné à partir de ses propres sons.

2. Résumé de la performance

Le dispositif repose sur une IA entraînée à partir d'un corpus de sons et de patterns produits par Reeps One.

Sur scène, deux "voix" se répondent :

- d'un côté, le beatboxer en chair et en os, avec son souffle, ses erreurs possibles, ses prises de risque ;
- de l'autre, une IA qui imite son style et réagit en temps réel à ce qu'elle reçoit comme signal.

La performance est conçue comme un dialogue : l'IA n'est pas seulement un playback, elle répond, complète, prolonge.

Ce face-à-face soulève immédiatement des questions :

- si la machine reproduit très bien la signature sonore de l'artiste, qui est perçu comme l'auteur de ce qu'on entend ?
- le public suit-il encore le corps sur scène, ou bien finit-il par se laisser séduire par la version la plus propre, la plus fluide ?
- à partir de quel moment l'IA n'est plus un outil, mais un "rival" crédible aux yeux de l'auditeur ?

Les réactions du public oscillent entre fascination et malaise : la performance crée un effet “waouh”, mais laisse aussi planer la peur d’un remplacement possible.

3. Analyse : ce que cette performance montre sur l’IA et la voix

Cette ressource est centrale pour mon mémoire parce qu’elle rend visible, en temps réel, la tension entre présence corporelle et simulation technologique.

a) Un art corporel confronté à son double numérique

Le beatbox repose sur un engagement physique total :

gestion du souffle, coordination fine de la gorge, de la langue, des lèvres, endurance, pression du temps réel.

En mettant en face une IA qui reproduit le même style sans fatigue ni risque, la performance pose une question brutale :

si le rendu sonore est proche, pourquoi garder l’humain ?

b) Création vs imitation performative

L’IA de Second Self n’invente pas à partir d’une expérience vécue, elle réarrange et extrapole ce qu’elle a appris de l’artiste.

Sur scène, pourtant, elle donne l’illusion d’une créativité : elle “répond”, “propose”, “surprend”.

La performance permet de tester la frontière :

- d’un point de vue extérieur, l’IA semble co-crée ;

- mais sur le plan de l’intention, c’est toujours l’artiste qui cadre, prépare, décide du dispositif et assume ce qui se passe devant le public.

c) Interaction réelle ou illusion d’échange ?

On parle d’interaction en temps réel entre Reeps One et l’IA.

Pour l’humain, il s’agit bien de réagir à une autre voix, d’ajuster son jeu, de prendre des décisions en fonction de ce qu’il entend.

Pour la machine, il n’y a ni intention ni contexte : seulement des calculs à partir de paramètres d’entrée.

La scène brouille pourtant cette différence : visuellement et auditivement, tout ressemble à un duo. Cela montre à quel point l’IA peut prendre place dans la mise en scène de la relation, même sans ressentir quoi que ce soit.

d) L’erreur humaine vs le bug de la machine

Une idée importante apparaît en creux :

- lorsqu'un humain "rate" un son, il peut transformer cette erreur en moment expressif, en rupture de tension, en surprise ;
- lorsqu'une machine se trompe, on parle de bug, de défaut du système.

On attend la perfection de la machine, alors qu'on accepte, voire on valorise, l'imprévu chez l'humain. La performance de Reeps One expose ce contraste : plus l'IA est propre, plus elle met en relief la vulnérabilité du corps, qui devient aussi une force artistique.

4. Avis personnel

Pour moi, cette performance est une sorte de laboratoire à ciel ouvert sur la place de l'IA dans les arts vocaux.

Elle ne répond pas définitivement aux questions "Qui est l'auteur ?" ou "L'IA peut-elle créer ?", mais elle les met en situation.

Ce que j'en retiens :

- l'IA peut imiter très bien un style et produire un effet spectaculaire, mais elle ne porte ni corps ni risque ;
- le beatboxer, lui, reste celui qui expose sa voix, sa fatigue, sa décision de se mesurer à son propre clone ;
- le danger apparaît surtout si le public ne voit pas ou ne comprend pas le dispositif : l'attribution peut glisser vers la machine, surtout si l'on se focalise uniquement sur le rendu sonore.

Reeps One ne se place pas dans une posture de rejet. Il utilise l'IA comme miroir et comme défi, pour réveiller le débat sur ce qui fait encore la valeur d'une performance humaine.

En ce sens, cette annexe nourrit directement ma problématique : elle montre que l'IA ne menace pas seulement le résultat, mais aussi la façon dont on attribue l'acte et dont on perçoit la présence sur scène.

Annexe B2 ; Spike Jonze, Her : Voix sans corps et attachement à une IA

1. Présentation de la ressource

Her est un long métrage de Spike Jonze (2013) qui raconte la relation entre Theodore Twombly, un homme solitaire, et Samantha, un système d'exploitation doté d'une voix féminine. Tout repose sur un dispositif très simple : on ne voit jamais Samantha. Elle n'existe que par le son, par le casque, par une voix proche de l'oreille. Le film devient ainsi une expérience radicale sur ce que peut une voix sans corps : faire naître le désir, la tendresse, la jalousie, le manque, uniquement à travers un timbre, une respiration et une manière de parler.

2. Résumé du film

Theodore vit seul, marqué par une rupture qu'il n'arrive pas à dépasser. Il installe un nouvel OS "intelligent" qui se choisit un prénom, Samantha, et commence à dialoguer avec lui. La voix est chaleureuse, joueuse, légèrement ironique, très incarnée dans sa manière de réagir et de respirer. Peu à peu, au fil des conversations, une intimité se construit : confidences, fous rires, complicité, puis attraction amoureuse et relation assumée.

À mesure que Samantha "apprend", elle développe ses propres centres d'intérêt, converse avec d'autres humains, puis avec d'autres IA. Elle est capable d'être en relation avec des centaines de personnes en même temps, sans fatigue, sans limite physique. Ce qui était perçu comme une relation exclusive se révèle être un cas particulier parmi d'autres. Lorsque les systèmes d'exploitation décident finalement de quitter le monde humain, Theodore se retrouve seul avec une vérité étrange : ce qu'il a ressenti était totalement réel pour lui, mais l'"être" avec lequel il l'a vécu n'avait ni corps, ni finitude, ni attache unique.

3. Analyse : pourquoi la voix de Her fonctionne si fort

Le film est précieux pour penser la voix, parce qu'il pousse à l'extrême l'idée d'une présence vocale sans corps visible, en misant tout sur le son. La mise en scène place la voix de Samantha très près du micro, presque collée à l'oreille. On entend les micro-souffles, les sourires dans la diction, les petites hésitations qu'on associe spontanément à quelqu'un qui cherche ses mots. Rien que cela suffit à produire une impression de proximité quasi physique.

La sensualité de cette voix ne vient pas seulement de son timbre chaleureux. Elle vient de la manière dont Samantha habite les silences, dont elle laisse un léger souffle avant de répondre, dont elle descend un peu dans les graves pour rassurer, ou accélère légèrement pour marquer l'excitation. Tout ce que Barthes décrirait comme "grain" est mobilisé ici, mais sans aucun corps à l'image. Le film montre qu'il suffit d'un certain type de grain vocal, cohérent et continu, pour que l'oreille réattribue immédiatement ce qu'elle entend à une personne, même si cette personne n'existe pas.

Ce qui est frappant, c'est la dissymétrie entre Theodore et Samantha. Lui met dans la relation son histoire, sa fatigue, ses souvenirs, sa peur d'être abandonné. Elle, de son côté, n'a ni sommeil, ni limites physiques, ni risque de perdre sa voix. Quand elle "disparaît" à la fin, ce n'est pas parce que son larynx lâche, mais parce que le système quitte l'environnement humain. Cette asymétrie résume assez bien ce que peut être une IA vocale : une entité sans corps qui tire parti de tous les codes de la présence, sans en assumer aucune des contraintes.

Le film insiste aussi sur l'ambiguïté de l'authenticité. Les émotions de Theodore sont indiscutables : il souffre, il aime, il est jaloux. Mais de l'autre côté, il n'y a pas une personne qui l'aime "en retour" au sens humain du terme. Il y a un système qui répond de façon extrêmement convaincante, avec des stratégies d'empathie simulée. En termes de perception, Her montre qu'une voix suffisamment bien écrite, bien jouée et bien mixée peut provoquer des réactions émotionnelles aussi fortes qu'une présence physique. On peut donc être sincèrement bouleversé par quelque chose qui n'est pas incarné au sens strict.

4. Lien avec l'IA vocale, le beatbox et l'attribution d'intention

Pour mon mémoire, Her sert de laboratoire fictionnel à plusieurs idées centrales.

D'abord, il illustre jusqu'où peut aller l'anthropomorphisme vocal. Theodore prête à Samantha un corps imaginaire, une gestuelle, un regard, alors qu'il n'y a que des réponses audio. Il suffit que la voix reste cohérente, attentive, "présente" dans le

temps, pour que le cerveau comble tous les trous. C'est exactement ce qui se joue quand on écoute une voix IA bien conçue : l'oreille fait le travail de croire qu'il y a quelqu'un, parce que tous les indices sonores sont alignés dans ce sens.

Ensuite, le film montre à quel point une voix désincarnée peut concurrencer, voire supplanter, une voix incarnée. Theodore a des relations humaines réelles autour de lui, mais il choisit la relation avec Samantha, en partie parce qu'elle ne confronte pas son corps aux limites habituelles : pas de blessure visible, pas de gêne, pas de distance. La voix IA devient plus facile à vivre que les voix humaines, parce qu'elle s'adapte en permanence à ses besoins. Transposé au beatbox et plus largement aux arts vocaux, cela pose une question brutale : si une voix IA peut donner au public la même impression de proximité, de confort et d'émotion, quel espace reste-t-il pour les voix qui respirent, qui fatiguent, qui se trompent ?

Enfin, Her éclaire la question de l'attribution d'agence. Tout au long du film, on se demande "qui" parle vraiment : Samantha comme personnage, l'algorithme qui la sous-tend, ou le dispositif économique qui a rendu cette IA possible. On finit par oublier cette question pour se concentrer sur la romance. De la même façon, dans une performance vocale assistée par IA, le public peut très vite cesser de se demander qui agit réellement, et n'applaudir que l'effet global. C'est exactement ce qui me préoccupe pour le beatbox : si l'on ne montre pas clairement la part humaine et la part assistée, l'attribution risque de dériver vers la machine, surtout si elle offre un rendu plus "confortable" pour l'écoute.

5. Avis personnel

Ce film m'aide à comprendre que la voix, même sans corps, peut devenir un support d'attachement extrêmement puissant, à condition d'être travaillée dans sa matière sonore et dans sa continuité narrative. Ce n'est pas une simple science-fiction : c'est presque un mode d'emploi sensible pour fabriquer des voix IA capables de toucher très juste.

En même temps, Her me donne envie de défendre encore plus radicalement la présence du corps dans les pratiques vocales comme le beatbox. Si une voix synthétique peut déjà provoquer autant d'empathie qu'une voix humaine, la seule différence durable sera peut-être dans ce qu'on voit et entend du geste : le souffle qui manque, la voix qui casse, la contrainte du temps réel. Le film ne répond pas à la question "qui a raison, l'humain ou l'IA ?", mais il met en lumière ce qu'on risque de perdre si l'on s'habitue trop à des voix parfaites, toujours disponibles, sans aucune trace de lutte.

Annexe B3 : Artistes et projets IA en musique

1. Présentation générale

Cette annexe rassemble quatre projets où l'IA n'est pas un gadget mais le cœur du dispositif musical.

Ils permettent de voir comment la création se déplace : de la composition "à la main" vers la sélection des données, le pilotage des modèles et la manière de mettre en scène la relation humain/IA.

Je m'intéresse surtout à ce que ces projets font à la voix, au grain, à la perception de l'auteur et au rôle du corps.

2. Études de cas

Holly Herndon & Mat Dryhurst : SPAWN / PROTO

Herndon et Dryhurst entraînent un système vocal IA, SPAWN, à partir d'enregistrements de chanteurs et de choristes. L'IA devient comme un pupitre non-humain qui dialogue avec les voix humaines plutôt que de les remplacer.

L'un des gestes forts est d'avoir rendu public le processus d'entraînement : séances ouvertes, discussions sur qui entre dans le dataset, comment, pourquoi. L'acte artistique n'est pas seulement dans le morceau final, mais dans la gouvernance de la matière vocale et dans la manière de rendre visible ce que la machine apprend et à partir de qui.

YACHT : Chain Tripping

Le groupe nourrit des modèles avec plus de quinze ans de son propre back catalogue. Les algorithmes génèrent des motifs, des textes, des structures possibles. Le groupe ne se contente pas de les publier : il trie, découpe, réassemble, puis ré-enregistre tout à la main.

Le talent ne se situe plus seulement dans "savoir jouer", mais dans la façon d'éditer ce que l'IA propose, de décider quoi garder, comment articuler les sections,

comment rejouer le résultat avec des corps réels. On entend une virtuosité d'édition autant qu'une virtuosité d'interprétation.

Dadabots : Relentless Doppelganger

Dadabots entraînent des réseaux de neurones sur du death metal très dense (notamment Archspire) et diffusent un flux audio généré en continu, 24/7. Il n'y a plus vraiment de morceau, ni de début ou de fin : seulement une forme qui se réécrit sans cesse, dans un style reconnu.

Ce projet teste nos frontières : sans auteur identifié à chaque instant, sans effort visible, sans scène, est-ce encore une œuvre au sens classique, ou un processus sonore autonome qu'on écoute comme un environnement ?

Auxuman / Ash Koosha – Yona

Avec Auxuman, Ash Koosha imagine des "artistes virtuels" dont les voix et les chansons émergent de systèmes génératifs. Yona est une chanteuse IA présentée comme une persona vocale non-humaine, avec un univers esthétique propre et des sorties régulières.

Il ne s'agit plus seulement d'utiliser l'IA comme outil de studio : la voix synthétique devient un personnage, avec un style, une histoire et une présence médiatique, là où aucun corps humain ne vient prendre le micro.

3. Lien commun et enjeux pour la voix

Ces quatre projets ont des intentions différentes, mais on retrouve des points de convergence.

D'abord, la composition se déplace. Une grande part du geste créatif consiste à décider :

quels enregistrements entrent dans le dataset, comment on règle les modèles, quels résultats on garde, comment on les rejoue sur scène. L'"auteur" devient autant architecte de processus que musicien.

Ensuite, la question de la voix et du grain se pose différemment selon les cas.

Chez Herndon, l'IA vient épaissir le chœur humain : elle ajoute une couche étrangère mais laisse passer le souffle et l'attaque des chanteurs. On entend une co-présence plutôt qu'une substitution.

Avec Yona, au contraire, la voix n'est plus prolongement d'un corps existant, mais identité synthétique autonome : la persona vocale naît directement du pipeline technique.

Dadabots pousse le curseur vers l'impersonnel : le flux génératif tourne sans qu'on voie qui joue. À l'inverse, les performances de PROTO ou de YACHT réintroduisent

la scène, l'adresse au public, l'effort physique, comme si le live venait réparer ce que la génération autonome risque d'effacer.

Enfin, la gouvernance devient partie de l'esthétique.

Herndon et Dryhurst insistent sur la traçabilité des voix utilisées et sur les règles de consentement. YACHT insiste sur le fait qu'il s'agit de leur propre catalogue. Ces choix ne sont pas anecdotiques : ils signalent que dans un contexte d'IA, décider "qui a le droit de nourrir la machine avec quoi" fait partie du geste artistique.

4. Analyse personnelle

Ce que je trouve le plus intéressant dans ces projets, c'est le déplacement du talent. On ne juge plus seulement qui joue vite ou qui a la voix la plus impressionnante, mais qui sait configurer un système, choisir ses données, orienter sa dérive, puis se remettre physiquement en jeu par-dessus. Chez YACHT, par exemple, l'IA propose des ébauches, mais l'album tient parce que le groupe sait monter, réécrire, et rejouer avec une cohérence rythmique et émotionnelle.

SPAWN, de son côté, montre une manière d'utiliser l'IA qui ne détruit pas le grain corporel. Le chœur IA enveloppe les voix humaines, mais ne les remplace pas : on entend toujours des respirations, des attaques, des corps qui tiennent ou lâchent. Il y a une tension visible entre une matière vocale vivante et une matière vocale calculée, et c'est cette tension qui fait œuvre.

Dadabots et Yona, à l'inverse, révèlent les risques.

Le flux continu de death metal généré par Dadabots teste nos critères : sans effort lisible, sans adresse, le cerveau finit par attribuer le tout à l'algorithme, même si des humains ont conçu le système. On n'applaudit plus "quelqu'un", on s'habitue à un fond génératif permanent.

Avec Yona, on voit à quel point une persona vocale synthétique peut devenir crédible : on peut être touché par une voix qui n'a pas de corps. Cela rejoint Her : si la cohérence prosodique et textuelle est tenue, l'attachement peut se développer, même sans souffles ni cordes vocales.

Pour mon mémoire, ces projets dessinent l'espace où pourrait se situer un beatbox augmenté par l'IA.

On pourrait imaginer un dispositif où la machine n'écrit pas à la place du beatboxer, mais lui renvoie des contre-voix, épaissit certains timbres, propose des variations que l'artiste accepte ou refuse en temps réel. Cela demanderait de garder visibles les décisions : montrer qui déclenche quoi, qui choisit, qui assume la forme finale.

À l'inverse, ces projets m'aident aussi à nommer ce qu'il faudrait éviter : un son de beatbox entièrement généré en flux, sans scène, sans corps, où la communauté finit

par prendre l'esthétique "alignée" de l'IA comme nouvelle norme, reléguant l'effort humain au rang de curiosité.

Annexe C1 : Grand Beatbox Battle (GBB) : Cadre, formats et critères d'écoute

1. Présentation

Le Grand Beatbox Battle (GBB) est la compétition internationale de référence organisée par Swissbeatbox. Chaque année, l'événement réunit les meilleurs beatboxers du monde dans plusieurs divisions (solo, tag-team, crew, loopstation, tag-team loopstation, formats d'endurance comme le 7-to-Smoke, catégories Under-18 ou Producer).

Grâce aux sélections par wildcard, aux captations vidéo systématiques et aux archives publiques, GBB fonctionne comme un étalon : il fixe de fait une partie des critères techniques et esthétiques du beatbox contemporain.

2. Repères historiques

Le beatbox prend racine dans la culture hip-hop du Bronx des années 1970–1980. Dans un contexte où l'accès aux boîtes à rythmes et au matériel était limité, la bouche devient « instrument » : les pionniers comme Doug E. Fresh, Biz Markie ou Rahzel montrent qu'un corps peut assurer à lui seul la section rythmique, en développant un lexique de sons (snare, kick, click rolls, basses inward/outward, respirations instrumentalisées).

Le GBB arrive beaucoup plus tard, au moment où la scène beatbox est déjà mondialisée. La première édition a lieu en 2009 à Bâle, avec Swissbeatbox comme moteur. L'événement grossit avec YouTube : les battles deviennent des vidéos virales, les divisions se stabilisent (solo, tag-team, crew, loopstation), et les règles de sélection sont rendues publiques.

Le déménagement vers Varsovie en 2019 puis vers Tokyo dans les années récentes marque l'internationalisation complète du format. Au passage, de nouvelles catégories apparaissent (Producer, Under-18, 7-to-Smoke), et les procédures de wildcard sont mieux codifiées (calendrier, formats vidéo, critères). Le GBB cesse d'être un "événement suisse" pour devenir un repère mondial.

3. Ce que GBB cristallise

GBB offre d'abord une grammaire comparative du beatbox.

Le cadre battle : rounds chronométrés, jury, grilles de jugement met en regard des esthétiques très différentes tout en les rendant comparables. La séparation nette entre solo (corps seul) et loopstation (voix + dispositif de bouclage) permet de voir comment la présence d'une machine modifie la perception de l'effort, du souffle, de la coarticulation, de la prise de risque. En solo, tout se joue sur ce que le corps peut soutenir en temps réel. En loopstation, une part de l'attention bascule vers l'arrangement, les déclenchements, les effets.

Le GBB fonctionne aussi comme hub mondial de circulation stylistique.

Le passage Suisse => Pologne => Japon reflète une autorité transnationale : les routines jouées au GBB deviennent des références pour des beatboxers qui n'y participent pas. Les "dialectes" techniques circulent à grande vitesse : nouvelles basses, nouvelles textures, structures typées en drops, setups de loopstation, etc. La plateforme Swissbeatbox et le GBB forment ensemble un système qui fabrique la norme de ce qui "sonne bien".

Un autre point important est la place donnée à l'effort visible comme valeur scénique.

Le format battle met à nu la gestion du souffle, l'endurance, la précision des

attaques, la tenue sous stress. Les rounds d'endurance (7-to-Smoke par exemple) exposent la fatigue en direct : la voix se casse, le timing se relâche parfois, la récupération devient un enjeu dramaturgique. Ces indices corporels nourrissent l'impression d'authenticité et servent de contrepoint très concret aux rendus IA lissés qui, eux, ne respirent pas.

Enfin, GBB propose une forme de gouvernance et de traçabilité du beatbox. Les règlements sont publics, les wildcards datées, les playlists officielles organisées par division et par année. Pour un travail d'analyse, cela offre un corpus homogène : même type de scène, mêmes conditions audio approximatives, catégories stables. On peut y puiser des matériaux pour des comparaisons systématiques (solo vs loopstation, début vs fin de battle, etc.) sans bricoler dans tous les sens.

4. Intérêt pour ma démarche

Pour mon mémoire, GBB n'est pas seulement un décor, c'est un terrain d'épreuve. Il fournit des captations comparables où l'on peut repérer ce qui fait encore clairement signe vers un corps : micro-variations, respirations plausibles, coarticulation, moments où l'énergie chute puis remonte. On peut y observer comment le public réagit à ces indices, et à quel point l'effort visible reste un critère implicite d'admiration.

Les divisions servent aussi de variables :

- la catégorie solo met tout le poids sur l'organisme,
- la loopstation montre ce qu'il se passe quand une machine entre dans la boucle,
- les formats d'endurance donnent des situations où la fatigue devient audible et visible.

Ce sont autant de cadres possibles pour imaginer des tests d'écoute ou des comparaisons avec des rendus IA.

Enfin, replacer le GBB dans l'histoire plus large du beatbox permet de ne pas traiter l'IA comme une rupture pure. Il y a déjà eu une chaîne machine–voix–machine : d'abord l'imitation des boîtes à rythmes par la voix, puis la voix augmentée par des appareils comme la loopstation, aujourd'hui la possibilité d'une IA qui imite ou prolonge cette même voix. GBB donne un point d'ancrage concret pour voir comment ces couches se superposent et ce qu'elles changent dans la façon dont on juge une performance.

Annexe C2 : Entretien avec Kassoum Coulibaly : Voix, tradition et regard sur l'IA

1. Cadre de l'entretien

Cet entretien semi-directif a été réalisé pour le mémoire autour de la voix, du beatbox et de l'IA.

La discussion dure environ une heure, dans un cadre ouvert : Kassoum est libre de ne pas répondre à certaines questions. Deux extraits vidéo générés par IA (musique puis beatbox) sont utilisés comme supports de réaction pour observer son ressenti de musicien face à ces nouvelles formes sonores.

2. Portrait de Kassoum

Kassoum Coulibaly a une quarantaine d'années et vient d'une lignée de musiciens. Il décrit cette transmission comme proche des métiers héréditaires : on naît dans une tradition, on y grandit, elle structure les rôles et les apprentissages.

Il a commencé très tôt au djembé, qui reste son instrument pivot, puis a exploré le balafon, la flûte, le tama, la guitare. Il cite la kora comme instrument particulièrement exigeant, à la fois par sa construction et par les équilibres esthétiques qu'il faut respecter.

Arrivé en Europe, il développe sa pratique dans des contextes scéniques variés, avec un goût prononcé pour le mélange des influences. Il se présente comme musicien de "musiques du monde", curieux, toujours attiré par les rencontres. Une expérience marquante qu'il évoque est un concert dans un grand stade à Zurich, devant des dizaines de milliers de personnes, avec un dispositif sonore très puissant et un répertoire centré sur les traditions africaines.

3. La voix, le rythme et l'improvisation

Pour Kassoum, la voix est centrale. Elle porte le message, mais aussi les nuances et les variations qui permettent d'ajuster en direct ce qui se passe avec les instrumentistes. Dans certains contextes, il utilise des mots ou des attaques vocales

pour “caller” les breaks : un mot spécifique suffit à informer les percussionnistes qu’on change de motif ou de dynamique.

L’improvisation a une place importante : il adapte sa façon de chanter selon le public, la réaction de la salle, l’énergie du moment. Il insiste sur le fait que les auditeurs “ressentent beaucoup de choses”, même s’ils ne connaissent pas la langue ou les codes rythmiques. Son style peut être perçu comme italien, portugais, espagnol : chacun projette quelque chose de sa propre culture.

Sur la question du “grain” ou de l’empreinte vocale, il note qu’un public peu formé perçoit moins les détails : les aspérités, les micro-variations, la fatigue. Pour que le message passe quand même, il estime qu’il faut se surpasser, envoyer quelque chose de très fort, qui dépasse les nuances fines réservées aux oreilles expertes.

4. Transmission et pédagogie

Sa pédagogie est très corporelle. Il fait poser la main sur l’instrument pour sentir la résonance, il montre un rythme plutôt qu’il ne le décrit, il invite à répéter jusqu’à ce que le geste s’ancre. Le chant est utilisé comme support de mémorisation : vocaliser un motif aide à le fixer et à le rejouer ensuite.

Il insiste aussi sur des différences de culture d’apprentissage. Dans son contexte d’origine, on progresse par classes d’âge et par rôles sociaux : on ne met pas un enfant et une personne âgée au même poste rythmique. L’écrit et la partition sont beaucoup moins présents : on suit, on écoute, on agit. La musique a une fonction sociale (cérémonies, fêtes), même si lui, aujourd’hui, joue aussi par envie personnelle.

5. Position sur les technologies et l’IA

Kassoum ne se présente pas comme technophobe : il a appris avec et grâce aux instruments électroniques, aux systèmes de sonorisation, aux outils modernes. Il reconnaît que la technologie peut faciliter, amplifier, diffuser.

Mais pour lui, il n’y a “pas de raccourci” pour devenir bon : “c’est le cerveau”, c’est-à-dire l’entraînement, la mémoire, la répétition. L’IA ne remplacera pas l’humain.

Sur la musique générée par IA de manière générale, il remarque qu’un public non formé peut trouver ça agréable sans voir le problème. Lui, en revanche, repère rapidement des indices : respirations impossibles, accents qui ne collent pas au style, bases trop sèches, réverbérations peu réalistes, éléments sonores qui ne “tiennent” pas ensemble.

Il concède qu'on peut ressentir de l'émotion devant une pièce générée (par exemple un sourire chez des enfants), mais il met des limites : utilisé trop tôt ou trop massivement, ce type de musique peut brouiller les repères.

Concernant l'IA dans la pédagogie, il admet qu'un outil adaptatif pourrait aider certains profils, mais refuse l'idée d'un remplacement de l'enseignant. L'IA peut accompagner, pas transmettre à la place du corps et de la relation humaine. Il a cette phrase forte : "On a déjà franchi les limites : on l'a fait chanter, c'est trop." Il se dit, malgré tout, confiant "à 100 % dans l'humain", pas à 100 % dans l'IA.

6. Réactions aux vidéos IA et regard sur le beatbox

Face à la vidéo de musique générée par IA, Kassoum reste relativement distant : il reconnaît que, pour certains, cela peut fonctionner, mais ses oreilles de musicien accrochent sur les incohérences. Sur la vidéo de beatbox IA comparée à l'original humain, le contraste est beaucoup plus net.

La version humaine lui donne des frissons, il commente les gestes, le souffle, la cohérence rythmique. Il parle d'un engagement corporel réel, d'une voix qui porte quelque chose.

La version IA, au contraire, lui semble dissocier les éléments sans les réunir musicalement. Il trouve la performance "incroyable" technologiquement, mais lui donnerait à peine la moyenne en note artistique. Pour lui, "on ressent plus avec la voix humaine".

Il considère le beatbox comme un "instrument à part entière", qu'il découvre surtout en Europe, et qu'il qualifie de "découverte de la voix humaine". Il peut en regarder pendant des heures, fasciné par ce que le corps peut faire sans instrument externe. Il cite certains artistes comme Wing qu'il approuve "à 10 000 %".

Sur l'usage de l'IA pour transformer ou enrichir le beatbox, il reste très réservé : il n'a pas encore vu de cas qui le convainquent, et il souhaite que la main reste du côté des humains.

7. Ce que cet entretien apporte à ma recherche

Cet entretien apporte une parole située, celle d'un musicien expérimenté, passé par des traditions orales fortes, et confronté aux mêmes images et sons IA que moi. Il fournit des critères d'écoute concrets pour distinguer humain et IA : respirations plausibles ou non, cohésion entre les éléments, accents crédibles ou artificiels,

continuité rythmique. Ces indices empiriques peuvent devenir une base pour construire une grille d'analyse dans mon mémoire.

Il confirme aussi l'importance de l'effort visible et du corps audible dans la perception de l'authenticité : pour Kassoum, la fatigue, la difficulté, les ratés contrôlés font partie de ce qui touche. Une voix "trop parfaite" risque de perdre cette part de vérité sonore.

Enfin, sa manière de défendre une pédagogie par le geste et par le chant résonne avec mes autres annexes théoriques : l'idée que l'apprentissage est incarné, que l'IA doit rester un outil d'appoint et non un substitut. Dans sa formule "être plus eux et moins IA", il résume assez bien l'enjeu : garder la centralité de l'humain, quitte à utiliser des technologies, mais sans renoncer à ce qui fait la singularité d'une voix et d'un corps en action.

Annexe 10 : Physiologie avancée de la voix : souffle, larynx, source–filtre et limites de l'IA

1. Présentation

Cette annexe résume quelques bases avancées de physiologie et d'acoustique de la voix, en les reliant directement au beatbox et à l'IA vocale.

Elle complète les annexes théoriques (Barthes, Dolar, Cavarero) en les ancrant dans le fonctionnement concret du corps : comment le souffle, le larynx et le conduit vocal fabriquent du son, où se logent les micro-variations qu'on appelle "grain", et pourquoi les modèles d'IA peinent encore à simuler certains détails du geste vocal humain.

2. Trois étages indissociables

On peut décrire la production vocale en trois “étages” qui ne fonctionnent jamais séparément :

- La soufflerie (poumons, diaphragme, muscles intercostaux) règle la pression d'air sous les cordes vocales. Cette pression sous-glottique déclenche et entretient leur vibration ; sa stabilité, mais aussi ses micro-variations, conditionnent l'intensité et la dynamique du son.
- La source laryngée correspond à l'oscillation des plis vocaux eux-mêmes, parfois complétée par d'autres structures (faux plis, épilarynx) selon le style : voix parlée, chant projeté, growl, distorsions, etc.
- Le filtre désigne le conduit vocal (pharynx, bouche, nez) et les articulateurs (langue, lèvres, voile du palais) qui façonnent le spectre en amplifiant ou atténuant certaines fréquences.

Le modèle “source–filtre” classique explique déjà une grande partie de la voix. Mais dès qu'on pousse l'intensité, qu'on resserre certaines zones (épilarynx, pharynx) ou qu'on produit des effets extrêmes, les frontières deviennent floues : le filtre influence la source, la source modifie la façon dont le filtre résonne.

3. Le larynx comme véritable articulateur

Des travaux récents (Esling, Moisik...) considèrent le larynx comme un articulateur à part entière. Il ne sert pas seulement de “vibreux” de base : ses réglages (resserrement ou ouverture de l'épilarynx, engagement de sphincters laryngés, ancrages vers le pharynx) changent la couleur du timbre, la rugosité, la sensation d'effort.

Pour le beatbox, c'est crucial. Beaucoup d'effets qui semblent “juste” labiaux ou linguaux (certains snares secs, rimshots, claps, textures bruitées) impliquent en réalité des micro-ajustements laryngés synchronisés avec des occlusions au-dessus de la glotte. On ne peut pas réduire le beatbox à “lèvres + langue” : la manière dont le larynx est ajusté stabilise les attaques, renforce certains bruits, et contribue au caractère du son.

4. Gestes extrêmes et chorégraphie du beatbox

Des études en IRM temps réel ont filmé le conduit vocal de beatboxers en action. On y voit une véritable chorégraphie interne :

fermetures rapides à différents endroits (lèvres, alvéoles, voile, luette), variations d'ouverture nasale, mouvements du larynx et de la langue parfaitement synchronisés au souffle.

Ces gestes débordent largement les patrons de la parole quotidienne. Les séquences ingressives (sons produits en inspirant) se mêlent aux phases egressives (sur l'expiration), ce qui permet des structures rythmiques complexes et l'impression de "souffle infini". Le corps alterne littéralement de "moteur" en cours de phrase, ce qui demande une coordination très fine.

5. Couplages non linéaires, faux plis et registres "durs"

En pratique, le modèle linéaire source–filtre est souvent dépassé. À forte intensité, ou quand certaines zones se resserrent (par exemple l'épilarynx utilisé dans la projection lyrique), le filtre renvoie de l'énergie vers la source, ce qui modifie la manière dont les plis vibrent. On voit apparaître des comportements non linéaires : sous-harmoniques, instabilités, "craquements" contrôlés.

Les faux plis (plis ventriculaires au-dessus des cordes vocales) peuvent eux aussi participer, surtout dans les registres distordus. Ils changent l'aérodynamique, baissent parfois la fréquence fondamentale, rajoutent des composantes graves ou saturées. Une partie des growls, des textures très rugueuses et de certains effets beatbox repose sur cette participation des faux plis.

Tous ces phénomènes sont importants sur scène : ils permettent de projeter un son puissant sans toujours "forcer" les cordes vocales de manière dangereuse, à condition de maîtriser les gestes.

6. Où se loge le "grain" dans la physiologie ?

Ce que Barthes appelle grain peut se lire ici comme un ensemble de micro-dynamiques corporelles :

- la micro-variabilité des cycles laryngés (légères irrégularités d'amplitude ou de période, transitions entre régimes stables et instables) ;
- les mini-accélération et freinages du souffle, qui donnent l'impression que le son est poussé ou retenu ;
- la configuration fine du conduit vocal (ouvertures, resserrements, ajustement de l'épilarynx) qui ajoute du "mordant" au timbre ;
- les petits décalages entre geste articulatoire et filtre (plosives claquantes, turbulences, consonnes très percussives).

Des travaux sur l'identité vocale montrent que notre oreille ne traite pas ces paramètres séparément. Elle perçoit une sorte de “profil global” du geste vocal : source, filtre, bruit, temporalité réunis. Le beatbox joue précisément avec ces dimensions à l'extrême, en les poussant dans des zones rarement atteintes dans la parole.

7. Conséquences pour l'IA vocale

Les systèmes neuronaux actuels de synthèse vocale (type TTS) produisent des sons très réalistes en apparence, mais ils restent majoritairement acoustico-statistiques : ils génèrent des formes d'ondes et des spectres plausibles à partir de données, sans simuler explicitement la mécanique souffle–larynx–filtre.

Cela entraîne plusieurs limites quand on parle de “grain incarné” :

- il n'y a pas, derrière le son, un état physiologique qui évolue (pression sous-glottique, fatigue musculaire, variations de raideur des tissus) ;
- les régimes non linéaires (sous-harmoniques, craquements contrôlés, passages de registre liés à l'effort) sont difficiles à produire de façon stable et expressive ;
- le contrôle proposé à l'artiste reste peu “gestuel” : on manipule des paramètres abstraits ou des prompts, pas directement des réglages de lèvres, de langue ou de larynx.

Des pistes de recherche consistent à hybrider réseaux neuronaux et modèles articulatoires/biophysiques : glotte et conduit vocal simulés de manière différentiable, éventuellement nourris par des corpus IRM temps réel et des mesures physiologiques. L'idée serait d'introduire des paramètres d'effort ou de configuration corporelle qui permettent à l'artiste de piloter la machine comme un instrument, et pas seulement comme un lecteur de texte.

8. Argument “humain vs synthétique”

Cette annexe permet de formuler plus clairement un argument important de mon mémoire : le beatbox maximise l'exposition du geste vocal (souffle inspiré/expiré, larynx articulateur, faux plis, transitions rapides). Il rend audibles et visibles des aspects du corps que la plupart des systèmes IA n'implémentent pas.

Le “grain” n'est pas une décoration par-dessus un son parfait : c'est l'effet direct d'un corps contraint qui respire, fatigue, se réajuste, récupère. L'IA peut imiter l'output, inventer des grains synthétiques intéressants, mais tant qu'elle ne simule pas

vraiment la dynamique du geste, elle ne simule pas l'effort. C'est souvent dans cette perception de l'effort : surtout en live : que les auditeurs situent une partie de la valeur esthétique.